

首都师范大学
本科生毕业论文（设计）

植物高分辨率图像超像素分割与多维特
征计算

**Superpixel segmentation and
multidimensional feature calculation for
high-resolution plant images**

院 系 资源环境与旅游学院

专 业 遥感科学与技术

年 级 2019 级

学 号 1193602010

指导教师 张爱武

论文作者 齐奥

完成日期 2023 年 5 月 11 日

首都师范大学本科生毕业论文（设计）原创性承诺书

论文（设计）题目	植物高分辨率图像超像素分割与多维特征计算		
学生姓名	齐奥	专业	遥感科学与技术
学号	1193602010	完成时间	2023 年 4 月 10 日 ~ 2023 年 5 月 11 日
指导教师姓名	张爱武	职 称	教授
<p>承诺内容：</p> <p>1、本毕业论文（设计）是学生<u>齐奥</u>在导师<u>张爱武</u>的指导下独立完成，凡涉及其他作者的观点和材料，均作了注释，如出现抄袭及侵犯他人知识产权的情况，愿按学校有关规定接受处理，并承担相应责任。</p> <p>2、学校有权保留并向上级有关部门送交本毕业论文(设计)的复印件和磁盘。</p> <p>备注：</p> <p style="text-align: right;">学生签名： 时间：</p>			

说明：学生毕业论文（设计）如有保密等要求，请在备注中明确，承诺内容第 2 条即以备注为准。

摘要

研究的研究对象为内蒙古海拉尔草原植物的高分辨率图像,旨在通过超像素分割,有效提取计算不同草种的多维特征信息,为后期草种识别服务。因此,本文采用一种简单线性迭代聚类(Simple Linear Iterative Clustering, SLIC)算法进行超像素分割,同时结合灰度共生矩阵、方向梯度直方图、局部二值模式和 RGB 颜色分布,色相饱和度亮度空间和 CIELab 颜色空间进行特征提取,在此基础上尝试使用随机森林进行草种分类。研究结果表明,通过采用超像素分割的方法,将图像分割成超像素区域,并将其输入随机森林分类器进行训练,从而获得了较好的分割效果。本研究的主要意义在于实现对植物图像的快速、准确的分割,为相关领域的研究提供了一定的参考价值。

关键词: 超像素分割、特征提取、随机森林、草种分类

Abstract

The research object of this study is high-resolution images of grassland plants in Hailar, Inner Mongolia. The aim is to effectively extract multidimensional feature information of different grass species through superpixel segmentation, which can serve as a basis for grass species recognition in later stages. Therefore, this study adopts a Simple Linear Iterative Clustering (SLIC) algorithm for superpixel segmentation, combined with Gray Level Co-occurrence Matrix (GLCM), Histogram of Oriented Gradient (HOG), Local Binary Pattern (LBP), RGB color distribution, Hue Saturation Value (HSV) space, and CIELab color space for feature extraction. On this basis, we attempted to use random forest for grass species classification. The results show that by using the superpixel segmentation method to divide the image into superpixel regions and inputting them into the random forest classifier for training, a good segmentation effect was obtained. The significance of this study lies in achieving fast and accurate segmentation of plant images, providing a certain reference value for related fields of research.

Key words: Superpixel segmentation, feature extraction, random forest, grass species classification

目录

第 1 章 绪论	- 1 -
1.1 研究背景与意义	- 1 -
1.2 国内外研究现状	- 1 -
1.3 研究内容与技术路线.....	- 2 -
第 2 章 图像收集和预处理	- 4 -
2.1 研究区域概况	- 4 -
2.2 数据源及数据预处理.....	- 4 -
第 3 章 研究方法	- 7 -
3.1 超像素分割	- 7 -
3.2 特征提取方法	- 9 -
3.3 分类方法	- 11 -
第 4 章 结果分析	- 13 -
4.1 超像素分割的结果分析	- 13 -
4.2 特征提取的结果分析	- 16 -
4.4 草种识别的结果分析	- 19 -
第 5 章 结论	- 21 -

第1章 绪论

1.1 研究背景与意义

中国草原面积 3.928 亿公顷，占国土面积的 40.9%。中国草原具有丰富的植被生态类型和草原景观类型，拥有大量世界著名优质牧草的野生种和伴生种，然而，受人类活动和气候变化的影响，草原正在面临着持续退化的威胁，这直接削弱了草原的生物多样性、生态系统服务和支持人类高生活质量的能力。

并且在当今的生态环境下，对于植物的研究和保护已经成为了一个极其重要的课题。利用计算机视觉等相关技术，对草原植物进行自动化识别，可以帮助其他研究高效准确的获取数据，同时也可以很好的实现自动化和数字化的草地资源管理。但由于草原植物种类繁多，植物叶片交叉层叠现象较为严重，图像处理的复杂度非常高，也就需要更多的计算资源支持。

植物高分辨率图像分割便是图像处理中的一项重要研究内容，其研究意义在于可以将一幅图像分成若干个具有独立性和可测度性的区域，进而提取出图像中的植物像元区域，并对这些区域进行计算、分析和比较，获取更为丰富的植物特征信息。而超像素分割技术作为一种有效的图像分割方法，可以通过将颜色、亮度、纹理等多维度信息聚合到一起，形成具有更高层次特征的超像素，提高植物高分辨率图像处理的效率和准确度。

综上所述，本文采用超像素分割和随机森林等相关技术，实现草原植物的分类识别，提高了草原植株识别的效率和自动化水平。

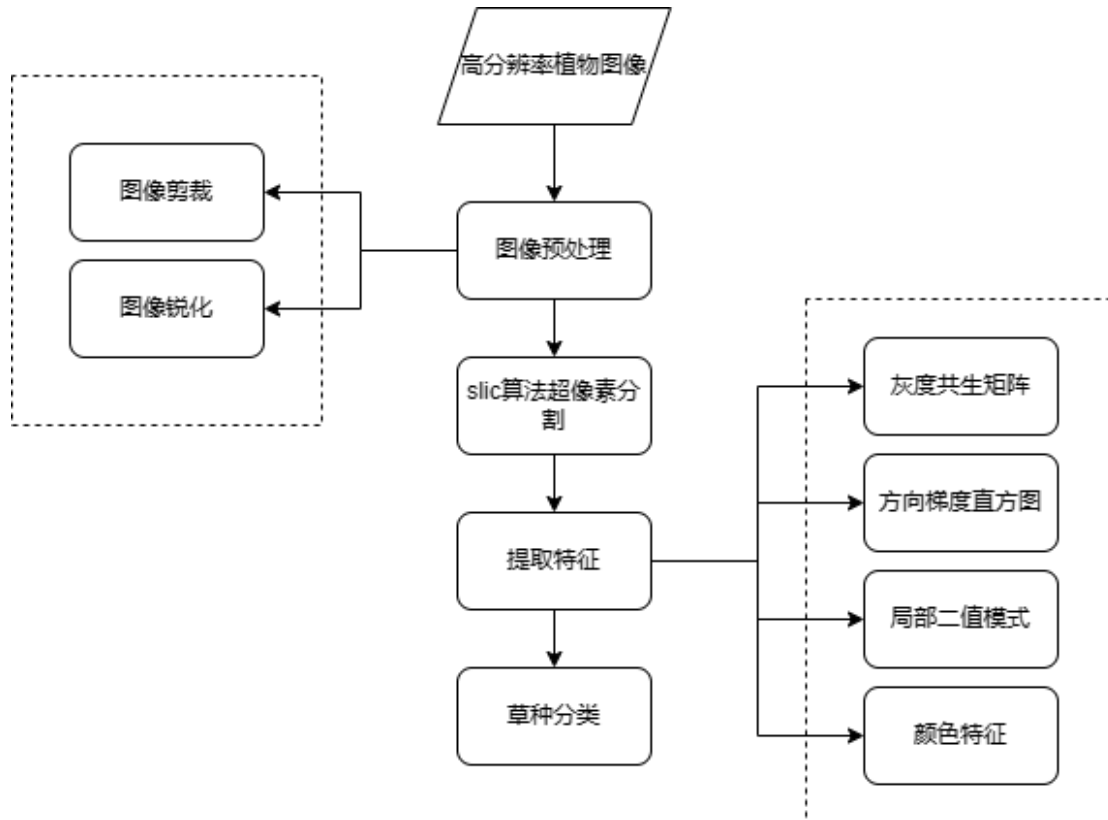
1.2 国内外研究现状

近些年研究将草原生态系统视为全球碳循环与能量守恒的生态参与者，并且确认草原生态系统一定程度上反映了全球气候的变化。国内外有很多学者都在此方向上做出了研究成果，例如王敬轩等人^[1]，对 14 类豆科牧草提取出叶片轮廓，在此基础上提取了包括圆形度、矩形度、横纵轴比等在内的 15 种特征，实现了这些豆科牧草的识别分类。Gebhardt 等人^[2]通过计算机视觉算法，对种植在德国波恩大学试验基地的不同比例的钝叶酸杂草和黑麦草实现了杂草识别。Hung 等人^[3]使用 Sparse 自动编码器特征学习对三种杂草进行了分类，三种草的分类精度分别达到了 72.2%、92.9%和 94.3%。Cheng 和 Matson 等人^[4]应用 Harris 角检测法查找叶尖和稻穗等感兴趣点，其次，提取周围每个点的多个特征送入机器学习算法中，来自动化区分水稻和杂草。Tellaecche 等人^[5]先对图像进行分割再基于支持向量机进行决策，以识别麦麸。

但这些研究没能很好的解决草原草种复杂纷繁，叶片交叠重错，无法很好实现自动化识别的问题。在其他研究方向上，超像素分割很好的起到了降低计算复

杂度的作用，所以本文也将采取这种方法进行研究。

1.3 研究内容与技术路线



这个研究步骤主要分为四个部分，包括图像预处理、超像素分割、特征提取、机器学习分类以及分类精度统计分析。

具体来说，高分辨率植物图像是通过固定高度的高清相机拍摄获得的。这种方法可以保证图像的清晰度和一致性，同时避免了由于相机角度或光照变化造成的失真。高分辨率植物图像可以用于植物识别、分类、生长监测等领域，为本研究提供了有价值的数据。

为了方便后续处理，需要对图像进行预处理，将图像分割为 512*384 像素的小图像。图像预处理的主要目的是消除图像中无关的信息，恢复有用的真实信息，增强有关信息的可检测性和最大限度地简化数据，从而改进特征提取、图像分割、匹配和识别的可靠性。

为了提取叶片的形状特征，我们首先将原始图像转换为灰度图像，并对其进行高斯滤波，以去除噪声和细节。接着，使用 slic 算法对小图像进行超像素分割，并将分割后的超像素聚类成具有叶片形状的图像。然后，我们计算每个聚类的凸包，并用其近似表示叶片的轮廓。最后，我们将凸包的顶点坐标作为叶片形状的特征向量，用于后续的分类和识别。

随后，对聚类好的超像素进行特征提取，包括计算颜色、纹理、形状等特征。颜色特征可以使用 $L^*a^*b^*$ 空间的均值和方差，纹理特征可以使用灰度共生矩阵，形状特征可以使用超像素的面积、周长、紧凑度等。这些特征可以用来描述超像

素的内部属性和边界信息，为后续的草种识别提供有效的依据。

为了减少特征冗余，对特征进行筛选，选出典型特征。这样可以提高模型的效率和准确性，避免过拟合的问题。特征筛选的方法有很多，例如基于统计的方法，基于信息论的方法，基于机器学习的方法等。不同的方法有不同的优缺点，需要根据具体的数据和任务来选择合适的方法。

接下来，采用随机森林的方法对筛选后的特征值进行分类。最后，对分类结果进行统计分析，计算分类精度。

第2章 图像收集和预处理

2.1 研究区域概况

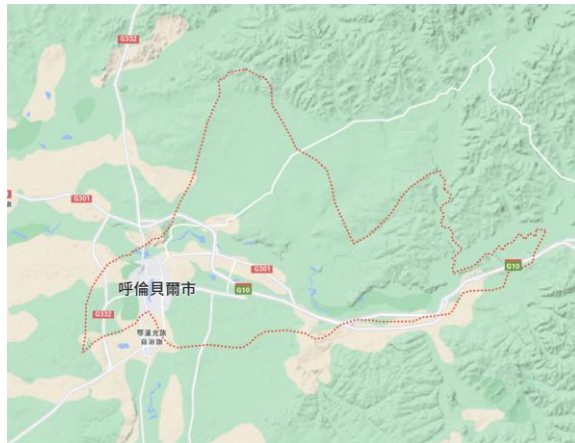


图 2.1 海拉尔区

研究区域位于中国内蒙古自治区东北部的海拉尔区。该区域位于大兴安岭西麓的低山丘陵和呼伦贝尔高平原的结合带上，海拉尔河上游距离 346 千米，区域范围为东经 $119^{\circ}30'48''$ — $120^{\circ}35'36''$ ；北纬 $49^{\circ}05'44''$ — $49^{\circ}27'15''$ 。该地区地势东高西低，属于“海拉尔内陆断陷盆地”，地貌类型多样，海拔高度在 603.0—776.6 米之间，相对高差 170 多米。该区域形成了三个地质单元，包括谢尔塔拉东山两个构造台地和“海拉尔盆地”。前者主要由高平地构成，后者则以低平地和河滩地为主，地貌类型可分为低山丘陵、高平地、低平地和河滩地。

该区域的气候属于中温带半湿润半干旱大陆性季风气候。由于该区域纬度偏高，远离海洋，加之大兴安岭的屏障作用，湿润的海洋性气候团的影响较弱。大部分时间，该地区受西伯利亚高压的控制，因此形成了春季多大风而少雨、蒸发量大，夏季温凉而短促、降水集中，秋季降温快、霜冻早，冬季严寒漫长、地面积雪时间长等气候特点。

2.2 数据源及数据预处理

2.2.1 数据来源

数据源是由团队成员使用高分辨率相机搭配固定高度支架在野外拍摄出的共 53 张植物影像，拍摄时间为 2022 年 8 月 31 日，每张图像大小为 8192×6144 。

本研究主要目标草种包含六种常见野生植物，分别是：



车前草



羊草



叉分蓼



菊叶委陵菜



唐松草



阿尔泰狗娃花

这其中，羊草是一种多年生草本植物，属于禾本科植物，是草原地区的主要优势牧草之一，它的适应性很强，能够在不同的气候条件下生长，同时也能够适应不同程度的草原退化。菊叶委陵菜是退化指示种，可以帮助判断草原退化程度。车前草是一种常见的草本植物，具有较强的适应性，可以在各种环境下生长。叉分蓼是一种适应性较强的草本植物，能够在草原、河滩、湿地等不同环境中生长，并能够与羊草形成伴生关系。唐松草是一种喜欢湿润环境的草本植物，具有较强的水分吸收能力，能够帮助保持草原生态系统的水分平衡。阿尔泰狗娃花则是一种花卉植物，具有较强的观赏价值，同时也能够在草原中生长，与羊草形成伴生关系。

通过对这些草种的分析,可以更好地评估草原生态系统的健康状况,并采取相应的措施保护草原生态系统的稳定和发展。同时,这些草种也为草原地区的畜牧业提供了重要的饲草资源,有助于维持当地畜牧业的发展。目前尚缺乏自然草地典型草种的特征数据库,本研究的目标之一就是提取计算典型草种的多维度特征。

2.2.2 数据预处理

为了对原始图像进行预处理,本文采用了以下步骤:

将原始图像裁剪成多个小块,每个小块的尺寸为 512×384 像素,共得到 256 个小图像。这样做的目的是为了降低 slic 超像素分割的计算复杂度,提高分割效率。

对每个小图像应用 Sobel 滤波器,进行边缘增强。由于原始图像中的背景是杂草,导致目标草种的叶片边缘模糊不清,因此需要通过锐化处理来增强边缘信息,从而提高 slic 超像素分割的准确性和质量,最后将经过边缘增强的小图像作为 slic 超像素分割的输入。

第3章 研究方法

3.1 超像素分割

超像素是由一组相邻的像素点组成的小区域，这些像素点在颜色、亮度、纹理等方面非常相似。这个概念最早是由加州伯克利大学计算机科学部的任晓峰等人于 2003 年提出的。与单个像素相比，超像素具有更多的研究价值，因为它们形成了具有边界信息和颜色信息的区域。在高分辨率遥感图像中，图像由无数细小像素构成，而绝大多数目标区域内存在大量特征完全一致的像素点。这些相同的像素点会浪费计算资源。超像素的出现很好地解决了这种情况，因为它们将这些相同的像素点聚合成一个集合，这样就可以减少计算量，同时保留了图像的重要信息。所以说，超像素是一种将相似的像素点聚合在一起以提高图像处理效率的技术。^[6]

本文采用了 SLIC 算法（Achanta 等人，2012）来进行超像素分割，算法的基本流程如下：

- 1.将图像划分为大小相等的网格（或称为“超像素”），每个网格为一个初始聚类中心。

- 2.对于每个初始聚类中心，向周围的 3x3 个网格搜索（即搜索 3x3 个相邻的超像素），并在搜索范围内寻找比当前聚类中心更接近目标颜色的像素。如果找到更接近目标颜色的像素，则更新该聚类中心的位置，否则保留原始位置。

- 3.对整个图像进行 K-means 聚类，将每个像素分配到最近的聚类中心。聚类中心位置将用来更新每个像素的超像素标签，以形成最终的超像素分割结果。

SLIC 算法的优点在于速度较快且可扩展性好，可以应用于大规模图像处理，同时其超像素的形状较为规则，易于后续的图像处理和分析。对于不同的目标草种进行分别进行参数调整可以获得较好的分割效果。

为了兼顾图像平面上的接近度和超像素的区域边界，slic 算法并没有采取 5D 空间中简单的欧几里得范数，而是使用了如下定义的距离度量：

$$D_{lab} = \sqrt{(l_k - l_i)^2 + (a_k - a_i)^2 + (b_k - b_i)^2} \quad (3.1)$$

Lab 是一种色彩空间，用于描述和比较不同颜色之间的差异。Lab 是 L（亮度）、a（从绿色到红色的颜色值）和 b（从蓝色到黄色的颜色值）三个参数的缩写。^[7]

Lab 距离是基于颜色的感知差异而设计的，因此它可以更好地描述人眼对颜色的感知。与其他色彩空间（如 RGB）相比，Lab 距离的优点是它可以更准确地表示颜色之间的差异，而不受颜色本身的亮度和饱和度的影响。因此，Lab 距离通常用于在设计、印刷、纺织、化妆品和食品等行业中进行颜色控制和质量控制。

$$D_{xy} = \sqrt{(x_k - x_i)^2 + (y_k - y_i)^2} \quad (3.2)$$

xy 平面距离为平面直角坐标系中两个点的直线距离。

$$D_s = d_{lab} + \frac{m}{S} d_{xy} \quad (3.3)$$

其中 D_s 为 lab 距离和 xy 平面距离由网格间隔 S 的归一化，同时在 D_s 中引入了一个变量 m，使得我们可以控制超像素的紧致程度。m 值越大，表明空间邻近性越突出，集群越紧凑，取值范围为[1:20]。^[8]

Python 中的 scikit-image 库中自带的 slic 函数便可以实现 SLIC 分割算法，它提供了一些可以调整的参数，包括：

Compactness，用于平衡超像素分割时颜色接近度和空间接近度的权重。当 Compactness 的值较高时，空间接近度的权重增加，这会使得超像素的形状更接近于方形，相应地，颜色接近度的权重较低，这会使得超像素更容易适应颜色的变化。相反，当 Compactness 的值较低时，颜色接近度的权重增加，使得超像素更注重颜色的相似性，但会导致超像素形状的不规则性增加。

另一个参数 Sigma 用于调整超像素分割前的高斯平滑程度，它表示高斯平滑内核的宽度或标准差。Sigma 的增大可以减少图像中的噪声，从而使得超像素分割更加平滑。

最后，参数 n_segments 用于控制超像素分割输出图像中的大约标签数。这个参数表示希望在图像中生成的超像素数量，可以通过调整该参数来控制超像素的数量和大小。较大的 n_segments 值会生成更多、更小的超像素，而较小的 n_segments 值则会生成更少、更大的超像素。

在进行植物叶片超像素分割时，需要根据不同植物叶片的形态特征以及图片背景的复杂程度来调整超像素分割的参数。其中，车前草、叉分蓼、羊草和唐松草等植物叶片的形状较为规则，因此我们可以使用一个较高的 compactness 值，以增加空间距离的权重，从而提高超像素分割的精度。此外，由于这些植物叶片的边缘颜色可能不够明显，我们还需要注意调整参数，以保证超像素分割结果的准确性。相反，阿尔泰狗娃花和菊叶委陵菜等植物叶片形状比较不规则，如果想要保留一定的形状特征，我们需要降低空间距离上的权重。同时，阿尔泰狗娃花在颜色上与背景差异较大，因此可以将 compactness 值调至更低，以增加颜色接近度的权重，从而使超像素更容易适应颜色的变化。在实际操作中，我们还需要根据具体情况进行参数调整，以获得更好的超像素分割效果。

对于较大的叶片，如羊草、车前草和阿尔泰狗娃花，如果想要保留更多的形状特征，我们可以调低 n_segments 的值，将一张图像分割成更少、更大的超像素。这样做可以确保超像素的形状更加规整，并且避免因超像素数量太多而导致的形状信息丢失。然而，需要注意的是，n_segments 的值应该根据实际情况进行调整，以便在保留形状特征的同时，获得更好的超像素分割效果。在选择超像素分割参数时，我们需要综合考虑不同因素的影响，以获得最优的超像素分割结果。

sigma 的值主要取决于想要切割的草种的叶片边缘是否清晰。如果叶片边缘非常清晰，那么可以设置一个较高的 sigma 值来减少图像中的噪点，并且使得分

割后的超像素更加平滑。相反，如果叶片边缘不够清晰，那么应该选择较低的 σ 值，避免模糊化边缘，影响超像素的形状和边缘的准确性。需要注意的是，不同草种的叶片特征不同，调整 σ 的值需要根据实际情况进行选择。如果需要保留草叶片的细节特征，则应该使用较小的 σ 值，这样可以保留更多的细节信息，同时避免噪声对分割结果的影响。

以此为依据大致确定参数范围，再通过反复调试得出每个草种的适用参数如下表。

表 3.1 分割参数

	车前草	羊草	叉分蓼	菊叶委陵菜	唐松草	阿尔泰狗娃花
compactness	25	40	20	15	30	10
σ	2	0	1	0	1	2
n_segments	150	130	200	175	200	65

3.2 特征提取方法

3.2.1 特征提取

本研究主要应用了四种特征提取方法，分别是灰度共生矩阵（Gray-level co-occurrence matrix）、方向梯度直方图（Histogram of oriented gradients）、局部二值模式（Local binary patterns）和 RGB, HSV 和 CIELab 空间的颜色分布。其中，灰度共生矩阵提取纹理信息，方向梯度直方图提取形状和外观信息，局部二值模式提取纹理信息，RGB, HSV 和 CIELab 空间的颜色分布提取颜色信息。^[9]

方向梯度直方图 (HOG) 是一种用于提取形状和外观特征的技术，它基于局部梯度或边缘方向的统计分布。Dalal 和 Triggs 在 2005 年首次提出了 HOG 方法，用于图像中的人物检测。该方法的核心步骤是，将图像划分为若干个单元格，计算每个单元格内所有像素的梯度方向直方图。为了降低光照变化的影响，对图像中重叠的单元格块进行对比度归一化处理。这些归一化后的块构成了 HOG 描述符，可以作为分类器或检测器的输入。

灰度共生矩阵 (GLCM) 是一种用于提取纹理信息的特征提取方法。GLCM 存储了图像中灰度级别为 i 和 j 的相邻像素之间的频率，这些频率表示相邻像素之间的角度关系和距离。在这个研究中，我使用了 4×4 的矩阵，距离为 1 和 2，角度为 0, 45 和 90 度，提取了 36 个特征，包括能量 (energy)、对比度 (contrast)、相关性 (correlation) 和同质性 (homogeneity)。^[10]

能量计算公式：

$$Energy = \sum_{i,j=0}^{N-1} (P_{ij})^2 \quad (3.4)$$

对比度计算公式：

$$Contrast = \sum_{i,j=0}^{N-1} P_{ij}(i-j)^2 \quad (3.5)$$

相关性计算公式：

$$Correlation = \sum_{i,j=0}^{N-1} P_{ij} \frac{(i-\mu)(j-\mu)}{\sigma^2} \quad (3.6)$$

同质性计算公式：

$$Homogeneity = \sum_{i,j=0}^{N-1} \frac{P_{ij}}{1 + (i-j)^2} \quad (3.7)$$

其中 N 为矩阵大小，在本研究中值为 4。i 和 j 分别表示矩阵中的行和列， P_{ij} 代表灰度共生矩阵中第 i 行第 j 列的元素值。

Local Binary Patterns (LBP) 是一种用于提取纹理信息的特征提取方法。它被广泛应用于各种场景中，因为它对灰度变化的不变性和计算效率的优势。LBP 的策略是观察中心点与其邻居之间的颜色变化，对图像中的所有像素执行此过程，并将其定义为中心点并分配其标签。然后，图像的像素标签直方图被用作纹理提取器。

在本研究中，我还提取了 RGB、HSV 和 CIELab 三种颜色空间每个通道的最小值、最大值、平均值和标准差等属性，共计 12 个特征。

通过以上特征提取方法，对 6 类草种共提取出 405 种特征值。为了使得这些特征值具有可比性，我们需要进行归一化处理，即将所有特征值缩放为标准差为 1，均值为 0 的范围内。这一步骤能够使得每个特征值对结果的影响具有平等性，并避免了某些特征值过大或过小对模型训练产生的负面影响。

3.2.2 特征选择

皮尔逊相关系数 (Pearson correlation coefficient) 是一种用于衡量两个变量之间线性相关程度的统计量，通常用符号 r 表示。皮尔逊相关系数的取值范围在 -1 到 1 之间，其中 -1 表示完全负相关，0 表示不相关，1 表示完全正相关。当两个变量之间的关系接近于线性关系时，皮尔逊相关系数可以有效地反映它们之间的相关程度。

皮尔逊相关系数的计算方法是基于两个变量的协方差和它们各自的标准差来计算的。具体而言，如果 x 和 y 是两个变量，它们的协方差为：

$$cov(x, y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n - 1} \quad (3.8)$$

其中，n 是样本大小， \bar{x} 和 \bar{y} 分别是 x 和 y 的样本均值。它们各自的标准差为：

$$s_x = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}} \quad (3.9)$$

$$s_y = \sqrt{\frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n-1}} \quad (3.10)$$

最终的皮尔逊相关系数为：

$$r = \frac{cov(x, y)}{s_x s_y} \quad (3.11)$$

如果 r 为正，表示 x 和 y 之间存在正相关关系；如果 r 为负，表示它们之间存在负相关关系。而 r 的绝对值越接近 1，表示它们之间的相关性越强。

对于特征重要性的计算，可以通过计算特征在模型的训练中所产生的错误来衡量其重要性。如果一个特征的值很好地区分了目标类别，那么在训练过程中，使用这个特征能够大大降低模型的错误率，因此这个特征会具有更高的重要性得分。

在随机森林中，每棵树的建立是基于袋装法和随机选择特征的，因此每个树都只使用了部分数据和部分特征进行训练。在这种情况下，对于一个特定的样本，可能只有部分树对其进行了分类，而其他树则没有对其进行分类。在这种情况下，我们可以使用这些未被用于该样本分类的树来评估该样本的分类效果，这就是 OOB 误差率的计算方法。

因此，对于一个特征的重要性得分，可以根据未被采样的样本集中该特征在每棵树中对样本的分类误差来计算。如果一个特征能够正确地将样本分类到其正确的类别，那么它在未被采样的样本集上的分类误差就会很低，而它的重要性得分就会很高。反之，如果一个特征的分类效果很差，那么它的重要性得分就会很低。

3.3 分类方法

分类方法可以分为有监督的分类和无监督的分类。有监督的分类是指已知数据的类别标签，需要根据训练数据建立一个分类模型，然后用该模型对新的数据进行预测。无监督的分类是指不知道数据的类别标签，需要根据数据的内在结构和相似度，自动地将数据划分为若干个类别或簇。^[11]

随机森林是一种监督分类方法，它是由多个决策树组合起来的集成学习方法。其流程如下：首先从输入的特征中随机选择一定数量的样本和特征，然后构建多个决策树，每个决策树都是基于不同的样本和特征构建的。最后，将多个决策树的结果进行投票或平均，得到最终的分类结果。随机森林的方法包括随机输入选择和随机线性组合。随机输入选择是指在每个节点上随机选择一个特征进行分裂，而随机线性组合是指将多个特征进行线性组合，然后再随机选择一个组合进

行分裂。这些方法可以提高随机森林的鲁棒性和泛化能力。^[12]

随机森林的优点包括速度快、对异常值和噪声的鲁棒性强，以及能够提供内部误差、强度、相关性和变量重要性的估计。此外，随机森林不容易过拟合，因为它们使用了多个决策树进行分类，而不是单个决策树。缺点是随机森林的结果不太容易解释，因为它们是由多个决策树组合而成的。此外，随机森林在处理高维数据时可能会出现一些问题，因为随机选择特征可能会导致一些重要特征被忽略。

第4章 结果分析

4.1 超像素分割的结果分析




图 4.1 车前草分割




图 4.2 羊草分割




图 4.3 叉分蓼分割



图 4.4 菊叶委陵菜分割



图 4.5 唐松草分割



图 4.6 阿尔泰狗娃花分割

通过观察可以发现，生成的超像素呈现出类似于细胞的紧凑形态，这种形态能够较好地贴合植物的边缘。对于叶片较小的唐松草来说，一个超像素几乎就能涵盖整个叶片。而对于阿尔泰狗娃花来说，由于它的颜色空间和背景的距离较大，因此在完整切割的同时也能保持较高的边缘贴合度。

然而，对于叶片较大、颜色空间和背景、交叠叶片距离较小的植物来说，为了保证不将背景杂草囊括进超像素的前提下，就需要牺牲一部分形状及相关特征值。这样做是为了避免对特征库造成污染。

4.2 特征提取的结果分析

如下表，本研究建立了一个包含 6 种草种（车前草、羊草、叉分蓼、菊叶委陵菜、唐松草和阿尔泰狗娃花）的多维特征样本数据库。其中，车前草、羊草、叉分蓼、菊叶委陵菜、唐松草和阿尔泰狗娃花的样本数分别为 81、75、117、93、75 和 129 个。对每个样本，提取了 4 类，共计 405 个特征。

表 4.1 车前草特征

样本序列号	r 通道最大值	灰度共生矩阵	Hu 矩	局部二值	...
1	196	17.317148	0.001015	0.001048	
2	195	17.40942	0.001052	0.001068	
3	213	17.433301	0.00102	0.001155	
4	233	12.317953	0.00111	0.001099	
5	217	22.343149	0.000878	0.001038	
...					

表 4.2 羊草特征

样本序列号	r 通道最大值	灰度共生矩阵	Hu 矩	局部二值	...
1	255	13.962308	0.003368	0.001068	
2	230	39.995699	0.00166	0.00174	
3	234	53.938478	0.002761	0.000814	
4	255	11.388036	0.00226	0.001017	
5	250	48.012333	0.001653	0.001648	
...					

表 4.3 叉分蓼特征

样本序列号	r 通道最大值	灰度共生矩阵	Hu 矩	局部二值	...
1	192	9.914083	0.002099	0.000605	
2	244	19.141308	0.001365	0.00175	
3	255	24.907025	0.001592	0.001266	
4	255	5.113279	0.001948	0.000346	
5	212	1.633755	0.036113	0.000168	
...					

表 4.4 菊叶委陵菜特征

样本序列号	r 通道最大值	灰度共生矩阵	Hu 矩	局部二值	...
1	216	28.314437	0.001676	0.001714	
2	190	15.970727	0.001659	0.001765	
3	207	20.640676	0.001282	0.00148	
4	188	20.860282	0.002065	0.001694	
5	203	16.452646	0.001322	0.001353	
...					

表 4.5 唐松草特征

样本序列号	r 通道最大值	灰度共生矩阵	Hu 矩	局部二值	...
1	225	18.621392	0.00158	0.001139	
2	239	23.757125	0.000967	0.001104	
3	189	17.285898	0.001062	0.000951	
4	249	20.1266	0.001438	0.001582	
5	239	32.786479	0.000897	0.001261	
...					

表 4.6 阿尔泰狗娃花特征

样本序列号	r 通道最大值	灰度共生矩阵	Hu 矩	局部二值	...
1	254	15.861587	0.000756	0.000559	
2	255	38.597266	0.00083	0.001551	
3	255	46.378496	0.000879	0.001246	
4	255	33.530914	0.000735	0.000844	
5	255	54.576576	0.000828	0.001851	
...					

虽然在本实验中样本量比较少，但在实际应用中可能会使用非常大量的样本，所以通过计算特征对于分类器的重要性，筛选出 25 个最重要的特征，在不影响分类精度的前提下降低后续所需的计算量。

表 4.7 特征重要性分数

特征名称	重要性分数	特征名称	重要性分数
ciel 通道标准差	0.63	g 通道均值	0.576
g 通道标准差	0.62	h 通道均值	0.575
v 通道标准差	0.619	h 通道标准差	0.575
r 通道标准差	0.603	s 通道标准差	0.574
b 通道标准差	0.598	glcm_corr_2_0	0.568
cieb 通道均值	0.592	glcm_cont_1_45	0.566
ciea 通道均值	0.591	glcm_cont_2_45	0.562
r 通道均值	0.589	glcm_corr_2_90	0.54
ciel 通道均值	0.582	glcm_cont_2_90	0.536
cieb 通道标准差	0.579	s 通道均值	0.533
ciea 通道标准差	0.579	glcm_cont_1_90	0.532
b 通道均值	0.578	glcm_asm_1_0	0.529
v 通道均值	0.578		

4.3 草种识别的结果分析

下表中分别为六类草种的八种识别精确度评价指标。真正例率（TP Rate）表示分类中表示在所有实际为正例的样本中，被模型正确预测为正例的比例。假正例率（FP Rate）表示在所有实际为负例的样本中，被模型错误预测为正例的比例。精确率（Precision）表示在所有被模型预测为正例的样本中，真正为正例的样本数量占比。召回率（Recall）表示在所有真正为正例的样本中，被模型正确预测为正例的比例。F1 分数（F-Measure）综合了 Precision（精确率）和 Recall（召回率）两个指标的优缺点，考虑到了分类模型对于正例和负例的分类准确度和对数据集不平衡的适应能力。马修斯相关系数（MCC）综合了真正例（TP）、真反例（TN）、假正例（FP）、假反例（FN）四个指标的值，可以评价模型在各个方面的性能。^[13]

最后，表格中还有一个加权平均值（Weighted Avg.），用于综合评估整个分类器的性能指标。

表 4.8 分类精度评价（特征筛选前）

类别	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area
车前草	0.914	0.006	0.961	0.914	0.937	0.927	0.994
羊草	0.973	0.01	0.936	0.973	0.954	0.947	0.999
叉分蓼	0.932	0.042	0.852	0.932	0.89	0.861	0.993
菊叶委陵菜	0.935	0.006	0.967	0.935	0.951	0.942	0.991
唐松草	0.96	0	0.999	0.96	0.98	0.977	0.998
狗娃花	0.961	0.002	0.992	0.961	0.976	0.97	0.997
Weighted Avg.	0.946	0.012	0.948	0.946	0.946	0.935	0.996

从表格中可以看出，分类器对各个类别的召回率和精确率表现较为平衡，且整体分类效果较好，加权平均数在各项指标上均超过了 0.9。其中唐松草的分类效果最好，精确率达到了 0.999，狗娃花和菊叶委陵菜的分类效果也较为优秀，精确率分别达到了 0.992 和 0.967。另外，除了叉分蓼以外，其他各个类别的 FP Rate 都比较低，说明误判率较小。叉分蓼的 FP Rate（误判率）为 0.042，比其他类别都要高。这可能是因为叉分蓼的特征与其他植物类别有一定的相似度，导致难以在分类时准确区分。此外，数据集中的叉分蓼样本数量较少，也可能会对分类结果产生影响。

在对特征进行筛选后再次使用随机森林进行分类后精度如下表，除了唐松草以外，其他草种分类精度都有极小幅度的提升。证明特征筛选不会降低分类精度，但是筛选前的分类精度已经足够高，所以特征筛选也不会显著提升分类器性能。

表 4.9 分类精度评价（特征筛选后）

类别	TP Rate	FP Rate	Precision	Recall	F- Measure	MCC	ROC Area
车前草	0.926	0.006	0.962	0.926	0.943	0.934	0.995
羊草	0.973	0.014	0.913	0.973	0.942	0.933	0.998
叉分蓼	0.932	0.031	0.886	0.932	0.908	0.884	0.979
菊叶委陵 菜	0.935	0.004	0.978	0.935	0.956	0.948	0.975
唐松草	0.973	0.010	0.936	0.973	0.954	0.947	0.988
狗娃花	0.930	0.005	0.984	0.930	0.956	0.944	0.995
Weighted Avg.	0.942	0.012	0.944	0.942	0.942	0.930	0.988




图 4.7 分类精确度变化

上图为通过特征重要度计算后，分别使用前 5、10、15、20、25 个特征值进行随机森林分类后，各个草种的分类精确度变化。结果表明，特征筛选后并不会严重降低分类精度。相反地，使用更少的特征可以大幅度减少计算量，提高分类效率。因此，特征筛选是一种有效的方式来简化分类模型，同时也可以避免过拟合和降低噪声对模型的影响。

第5章 结论

为了提高草原草种的分类识别准确率和效率,以及推动草原草地的自动化及数字化治理,本文提出了一种研究方法。该方法包括三个步骤:分割、特征提取和识别。

其中,利用基于 slic 分割算法的方法进行图像分割,得到类似于细胞一样紧凑的超像素,这些超像素可以很好地适应图像的边缘和细节,从而除去了图像中不必要的冗余信息。通过特征提取和筛选,构建了多维特征体系,分别提取了车前草、羊草、叉分蓼、菊叶委陵菜、唐松草和狗娃花的纹理、形状、颜色等共 405 个特征,经过筛选后每类草种的特征库收录了 25 种特征值。识别分类是通过测试良好的随机森林框架进行的,得到了超过 90% 的精度。

证明了该方法在草原草种的分类识别方面具有较好的应用前景。

但由于部分特征之间的关联性不呈线性分布,使用皮尔逊相关系数来衡量它们的相关程度可能会产生误差。因此,为了提高研究的准确性,未来可以对特征选择的方法进行改进。

参考文献

- [1] 王敬轩, 冯全, 王宇通, 等. 基于图像识别技术的豆科牧草分类研究[J]. 草地学报, 2010, 18(1): 37.
- [2] Gebhardt S, Schellberg J, Lock R, 等. Identification of broad-leaved dock (*Rumex obtusifolius* L.) on grassland by means of digital image processing[J]. Precision Agriculture, Springer, 2006, 7: 165–178.
- [3] Hung C, Xu Z, Sukkarieh S. Feature Learning Based Approach for Weed Classification Using High Resolution Aerial Images from a Digital Camera Mounted on a UAV[J]. Remote Sensing, 2014, 6(12): 12037–12054.
- [4] Cheng B, Matson E T. A Feature-Based Machine Learning Agent for Automatic Rice and Weed Discrimination[A]. L. Rutkowski, M. Korytkowski, R. Scherer, 等. Artificial Intelligence and Soft Computing[C]. Cham: Springer International Publishing, 2015: 517–527.
- [5] Tellaeche A, Pajares G, Burgos-Artizzu X P, 等. A computer vision approach for weeds identification through Support Vector Machines[J]. Applied Soft Computing, 2011, 11(1): 908–915.
- [6] 王春瑶, 陈俊周, 李炜. 超像素分割算法研究综述[J]. 计算机应用研究, 2014, 31(1): 6–12.
- [7] Zhang X, Wandell B A. A spatial extension of CIELAB for digital color image reproduction[A]. Citeseer, 1996, 27: 731–734.
- [8] Achanta R, Shaji A, Smith K, 等. Slic superpixels[R]. 2010.
- [9] Dos Santos Ferreira 等 - 2017 - Weed detection in soybean crops using ConvNets.pdf[J]. .
- [10] Mohanaiah P, Sathyanarayana P, GuruKumar L. Image texture feature extraction using GLCM approach[J]. International journal of scientific and research publications, Citeseer, 2013, 3(5): 1–5.
- [11] Cunningham P, Cord M, Delany S J. Supervised learning[J]. Machine learning techniques for multimedia: case studies on organization and retrieval, Springer, 2008: 21–49.
- [12] 方匡南, 吴见彬, 朱建平, 等. 随机森林方法研究综述[J]. 统计与信息论坛, 2011, 26(3): 32–38.
- [13] Breiman L. Random forests[J]. Machine learning, Springer, 2001, 45: 5–32.

致谢

岁月如梭，转眼间我的本科学业即将画上句号。在此，我要向那些为我毕业论文的顺利完成付出心血和汗水的人们致以最崇高的敬意和感激之情。

首先，我要向我的导师张爱武教授表达我最真挚的谢意。她为我提供了深入、全面的指导，帮助我理清研究思路、准确定位研究方向，使我的论文研究充满了智慧和创新，她的谆谆教诲和严谨治学的精神将永远铭刻在我的心中。

其次，我还要特别感谢我的学长陈云生博士，他给予了我很多宝贵的指导和帮助。在我的学术研究和论文写作过程中，他给予了我很多关键性的建议和指导，使我能够更加深入地理解研究问题、更加准确地表达研究结果。他/她的专业知识和经验对我产生了巨大的启发和影响，使我对学术研究的理解和认识更加深刻和全面。

此外，我也要感谢我的同学们和朋友们。在我们的学术和生活中，他们是我的知音，他们和我一同探索、学习、成长，在相互鼓励、支持和帮助中走过了难忘的岁月。他们的友谊将伴随我一生，成为我人生旅途中最宝贵的财富。

最后，我要感谢所有帮助过我的人们。他们的帮助和支持使我能够克服困难，充分发挥自己的潜力和才华，完成本篇毕业论文。他们在我的学习和研究道路上给予了我无私的帮助和指导，他们的辛勤付出和真诚关怀使我受益匪浅。

感谢你们所有人的支持和关心。我将永远怀着感激之情，不断努力，为实现自己的梦想而奋斗。